



**TECNOLÓGICO NACIONAL DE MÉXICO
INSTITUTO TECNOLÓGICO DE CUAUTLA**

**INGENIERÍA EN SISTEMAS COMPUTACIONALES
ESPECIALIDAD INTELIGENCIA DE NEGOCIOS Y CIENCIA
DE DATOS
SÉPTIMO SEMESTRE**

**AGOSTO - DICIEMBRE 2026
INFORME TÉCNICO - UNIDAD I**

**PROYECTO INTEGRADOR 1
DISEÑO Y SIMULACIÓN DE SISTEMAS CONTROLADOS**

**PRESENTADO POR:
KEREN SARAI VILLANUEVA LOPEZ**

**DOCENTE:
ARÍSTIDES CABALLERO ALFARO**

**CUAUTLA, MORELOS, MÉXICO
SEPTIEMBRE, 2026**

Índice

1. Introducción	1
2. Objetivos de la actividad	1
2.1. Objetivo general	1
2.2. Objetivos específicos	1
3. Marco teórico	2
3.1. Toma de decisiones basada en datos	2
3.2. Tipos y fuentes de datos	2
3.3. Ética y privacidad en el manejo de datos	2
4. Herramientas utilizadas	2
5. Desarrollo	3
5.1. Actividad 1: Ingesta de datos remotos mediante API REST	3
5.2. Actividad 2: Consulta analítica de negocio	3
5.3. Actividad 3: Anonimización	4
5.4. Registro de comandos (log)	5
6. Conclusión	6

Índice de figuras

1.	Resultado de la consulta de la tabla con datos crudos.	3
2.	Resultado de la consulta analítica por ciudad.	4
3.	Resultado de la consulta de la tabla con los datos seguros.	5
4.	Fragmento del log de comandos generado por DuckDB CLI.	6

1. Introducción

La gestión y el análisis de grandes volúmenes de datos exigen seleccionar sistemas de almacenamiento y procesamiento eficientes que permitan recuperar la información en tiempos óptimos. [1] Los sistemas de gestión de bases de datos relacionales (SGBD SQL) permiten estructurar la información en esquemas definidos e interpretar consultas para manipular datos. [1] En este marco, evaluar el rendimiento y el comportamiento de las tecnologías de bases de datos resulta fundamental para determinar la herramienta más adecuada ante un dominio de datos específico.

El presente informe documenta el desarrollo de la práctica correspondiente a la Unidad I: *Fundamentos de Análisis de Datos*, la cual abarca los temas de toma de decisiones basada en datos, tipos y fuentes de datos, y ética y privacidad en el manejo de información. Como herramienta de trabajo se utilizó **DuckDB** en su modalidad de línea de comandos (CLI), sobre una base de datos local persistente (`proyecto_unidad1.db`).

2. Objetivos de la actividad

2.1. Objetivo general

Aplicar los fundamentos del análisis de datos (toma de decisiones, tipos y fuentes de datos, y ética y privacidad) mediante la implementación de un pipeline completo de ingesta, transformación y anonimización de datos utilizando DuckDB como motor analítico local.

2.2. Objetivos específicos

- Ingestar datos remotos desde una API REST pública hacia una base de datos local persistente.
- Construir una consulta analítica agregada que responda a una necesidad de negocio concreta, aplicando funciones de agregación y extracción de subestructuras JSON.
- Aplicar el principio de *Privacy by Design* mediante la anonimización de datos personales identificables (PII) en la etapa más temprana posible del pipeline.
- Documentar el proceso mediante un registro (log) reproducible de los comandos ejecutados.

3. Marco teórico

3.1. Toma de decisiones basada en datos

El análisis de datos como apoyo a la toma de decisiones consiste en transformar datos crudos en información agregada y accionable. [2] Esto se logra mediante operaciones de agrupación (`GROUP BY`) y funciones de agregación (`COUNT`, `MIN`, `MAX`, entre otras), que permiten resumir grandes volúmenes de registros individuales en indicadores que respondan a preguntas concretas del negocio.

3.2. Tipos y fuentes de datos

Las fuentes de datos pueden clasificarse, entre otros criterios, según su origen (internas o externas) y su formato (estructurado, semiestructurado o no estructurado). [3] En esta práctica se trabajó con una fuente externa semiestructurada: un endpoint REST que expone información en formato JSON, consumido directamente por el motor analítico mediante la función `read_json_auto`, sin necesidad de un proceso ETL intermedio.

3.3. Ética y privacidad en el manejo de datos

El principio de *Privacy by Design* (Cavoukian) [4] establece que la protección de datos personales debe integrarse desde el diseño mismo del sistema, y no añadirse como una capa posterior. Uno de sus principios derivados es la **minimización de datos**: solo debe conservarse la información estrictamente necesaria para el propósito declarado. [5] En el contexto de esta práctica, esto se traduce en anonimizar la información personal identificable (PII) —como correo electrónico y teléfono— en la etapa de ingesta, antes de que dicha información quede disponible para consultas analíticas posteriores.

4. Herramientas utilizadas

- DuckDB CLI (versión reciente, con soporte de *autoload* de extensiones).
- Fuente de datos: endpoint público REST/JSON `https://jsonplaceholder.typicode.com/users`. [6]

5. Desarrollo

5.1. Actividad 1: Ingesta de datos remotos mediante API REST

Para permitir que DuckDB realice solicitudes HTTP es necesaria la extensión `httpfs`, la cual se autocarga en versiones recientes al detectar una URL en la consulta. Dicha extensión introduce el parámetro de configuración `force_download`, que fuerza la descarga completa del recurso remoto en lugar de usar solicitudes de rango (*range requests*) parciales, evitando así desbordamientos o lecturas incompletas del búfer HTTP al consumir el endpoint JSON.

Listing 1: Configuración del búfer HTTP e ingesta de datos remotos

```
1  -- 1. Configurar el motor para descargar el recurso remoto por
    completo
2  -- y evitar desbordamientos en el bufer HTTP
3  SET force_download=true;
4
5  -- 2. Ingesta directa de la API JSON a una tabla persistente
6  CREATE TABLE datos_raw AS
7  SELECT * FROM read_json_auto('https://jsonplaceholder.typicode.
    com/users');
8
9  -- 3. Confirmamos que se creo correctamente la tabla a partir del
    archivo json
10 SELECT * FROM datos_raw LIMIT 2;
```

id int64	name varchar	username varchar	...	phone varchar	website varchar	company struct("name" varchar, catc...
1	Leanne Graham	Bret	...	1-770-736-8031 x56442	hildegard.org	{'name': Romaguera-Crona, '...
2	Ervin Howell	Antonette	...	010-692-6593 x09125	anastasia.net	{'name': Deckow-Crist, 'cat...

2 rows use .last to show entire result 8 columns (6 shown)

Figura 1: Resultado de la consulta de la tabla con datos crudos.

5.2. Actividad 2: Consulta analítica de negocio

Se elaboró un reporte consolidado por ciudad que muestra el total de usuarios, el número de dominios de correo distintos y la extensión geográfica (latitud mínima y máxima), restringido a ciudades que cuenten con al menos un usuario cuyo `id` sea un número par.

La condición sobre el `id` par se aplicó con `HAVING` en lugar de `WHERE`, ya que es una condición sobre el grupo (ciudad) y no sobre cada fila individual; filtrar con `WHERE` antes de agrupar excluiría usuarios de `id` impar del conteo total, alterando el resultado solicitado.

Listing 2: Consulta analítica con funciones agregadas y extracción de subestructuras JSON

```

1 SELECT
2     address.city AS ciudad,
3     COUNT(id) AS total_usuarios,
4     COUNT(DISTINCT regexp_extract(email, '@(.*)$', 1)) AS
5         dominios_diferentes,
6     MIN(CAST(address.geo.lat AS DOUBLE)) AS latitud_minima,
7     MAX(CAST(address.geo.lat AS DOUBLE)) AS latitud_maxima
8 FROM datos_raw
9 GROUP BY address.city
10 HAVING SUM(CASE WHEN id % 2 = 0 THEN 1 ELSE 0 END) > 0
11 ORDER BY total_usuarios DESC, ciudad ASC;
```

ciudad varchar	total_usuarios int64	dominios_diferentes int64	latitud_minima double	latitud_maxima double
Aliyaview	1	1	-14.399	-14.399
Lebsackbury	1	1	-38.2386	-38.2386
South Christy	1	1	-71.4197	-71.4197
South Elvis	1	1	29.4572	29.4572
Wisokyburgh	1	1	-43.9509	-43.9509

Figura 2: Resultado de la consulta analítica por ciudad.

5.3. Actividad 3: Anonimización

Se aplicaron los principios de *Privacy by Design* y minimización de datos. De los dos escenarios propuestos, se optó por el **Escenario B (anonimización en la ingesta)**: se genera una vista intermedia anonimizada inmediatamente después de leer la fuente primaria, y la tabla persistente final solo conserva la versión anonimizada. La tabla cruda (`datos_raw`) se elimina una vez generada dicha vista, para que la PII completa nunca quede disponible para consultas posteriores.

Listing 3: Anonimización mediante expresiones regulares (motor RE2) y limpieza de datos crudos

```

1 -- Escenario B: anonimizacion en la ingesta.
```

```

2  -- Se descarta la PII antes de que cualquier analista pueda
    consultarla,
3  -- cumpliendo Privacy by Design y minimizacion de datos.
4
5  CREATE VIEW v_datos_anonimizados AS
6  SELECT
7      id,
8      name,
9      regexp_replace(email, '^(.{2}).*(@.*)$', '$1*****$2') AS
        email_protegido,
10     regexp_replace(phone, '.*(.{4})$', '***-***-$1') AS
        telefono_protegido,
11     address.city AS ciudad,
12     company.name AS empresa
13 FROM datos_raw;
14
15 CREATE TABLE historico_usuarios_seguro AS
16 SELECT * FROM v_datos_anonimizados;
17
18 -- Visualizamos algunos datos de la tabla anonimizada:
19 SELECT * FROM historico_usuarios_seguro LIMIT 5;
20
21 -- Eliminacion de la tabla cruda para no conservar PII en disco
22 DROP TABLE datos_raw;

```

id int64	name varchar	email_protegido varchar	telefono_protegido varchar	ciudad varchar	empresa varchar
1	Leanne Graham	\$1*****\$2	***_***-\$1	Gwenborough	Romaguera-Crona
2	Ervin Howell	\$1*****\$2	***_***-\$1	Wisokyburgh	Deckow-Crist
3	Clementine Bauch	\$1*****\$2	***_***-\$1	McKenziehaven	Romaguera-Jacobson
4	Patricia Lebsack	\$1*****\$2	***_***-\$1	South Elvis	Robel-Corkery
5	Chelsey Dietrich	\$1*****\$2	***_***-\$1	Roscoeview	Keebler LLC

Figura 3: Resultado de la consulta de la tabla con los datos seguros.

5.4. Registro de comandos (log)

Para cumplir con el entregable del log de comandos, se redirigió la salida del CLI de DuckDB hacia un archivo local antes de ejecutar la práctica, y se restauró al finalizar.

Listing 4: Redirección de la salida del CLI a un archivo de log

```

1  -- 1. Redirigir la salida de la terminal a un archivo
2  .output log_comandos_numcontrol_U1.txt
3
4  -- 2. Activar el eco de los comandos ejecutados
5  .echo on
6
7  -- 3. A partir de aqui se ejecuta la practica normalmente
8  -- (Actividades 1, 2 y 3)
9
10 -- 4. Restaurar la salida a pantalla al finalizar
11 .output stdout

```

El archivo generado, `log_comandos_23680116_U1.txt`, se adjunta como entregable independiente en formato `.txt`.

```

pit > .logs_comandos_23680116_U1.txt
1  SET force_download=true;
2
3  CREATE TABLE datos_raw AS
4
5  SELECT * FROM read_json_auto('https://jsonplaceholder.typicode.com/users');
6  SELECT * FROM datos_raw LIMIT 2;
7
8  | id | name       | username | email          | struct(street varchar, suite
9  | int64 | varchar | varchar | varchar |
10
11 | 1 | Leanne Graham | Bret    | Sincere@april.biz | {'street': Kulas Light, 'suite': Apt. 55
12 | 2 | Ervin Howell | Antonette | Shanna@melissa.tv | {'street': Victor Plains, 'suite': Suite
13
14
15 SELECT
16 address.city AS ciudad,
17 COUNT(id) AS total_usuarios,
18 COUNT(DISTINCT regexp_extract(email, '@(.*)$',1)) AS dominios_diferentes,
19 MIN(CAST(address.geo.lat AS DOUBLE)) AS latitud_minima,
20 MAX(CAST(address.geo.lat AS DOUBLE)) AS latitud_maxima,
21 FROM datos_raw
22 WHERE id % 2 = 0
23 GROUP BY address.city
24 ORDER BY total_usuarios DESC, ciudad ASC;
25

```

Figura 4: Fragmento del log de comandos generado por DuckDB CLI.

6. Conclusión

Este proyecto permitió poner en práctica, de manera integrada, los tres grandes temas de la unidad: cómo los datos apoyan la toma de decisiones, de dónde vienen y en qué forma llegan, y qué responsabilidad ética implica manejarlos. Más allá de las herramientas específicas

utilizadas, el ejercicio deja una idea central: los datos por sí solos no dicen nada útil hasta que se organizan y resumen de forma que respondan una pregunta concreta, como en este caso conocer cuántos usuarios hay por ciudad o qué tan dispersos están geográficamente.

También quedó claro que trabajar con datos personales no es un detalle menor. Aunque la información utilizada era de prueba, el ejercicio de anonimizarla desde el primer momento ayuda a entender por qué la privacidad debe pensarse desde el diseño del sistema y no como un parche posterior. Esto conecta directamente con situaciones reales: cualquier proyecto que maneje información de personas, sin importar su tamaño, debería seguir este mismo criterio de proteger lo sensible desde el origen.

Finalmente, el proceso reforzó la importancia de documentar y dejar evidencia de cada paso realizado, no solo como requisito de entrega, sino como una buena práctica que facilita revisar, corregir y repetir el trabajo en el futuro si fuera necesario.

Referencias

- [1] M. Barrionuevo and M. E. Rodríguez, “Análisis de performance de base de datos SQL y NoSQL aplicado a datos de entidades públicas,” 2023.
- [2] GeeksforGeeks, “SQL for Business Analysts,” 7 2025.
- [3] Bridge, “Diferencias entre datos estructurados, no estructurados y semiestructurados,” 7 2024.
- [4] A. Cavoukian, “Privacy by design: The 7 foundational principles,” tech. rep., Information and Privacy Commissioner of Ontario, Canada, 2009.
- [5] Parlamento Europeo y el Consejo de la de la Unión Europea, “Reglamento (UE) 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos (Reglamento General de Protección de Datos).” DO L 119 de 4.5.2016, p. 1–88, 2016. Art. 25: Protección de datos desde el diseño y por defecto.
- [6] JSONPlaceholder, “Free fake api for testing,” 2026.