



**TECNOLÓGICO NACIONAL DE MÉXICO
INSTITUTO TECNOLÓGICO DE CUAUTLA**

**INGENIERÍA EN SISTEMAS COMPUTACIONALES
ESPECIALIDAD INTELIGENCIA DE NEGOCIOS Y CIENCIA
DE DATOS
SÉPTIMO SEMESTRE**

**AGOSTO - DICIEMBRE 2026
INFORME TÉCNICO - UNIDAD 2**

**PROYECTO INTEGRADOR UNIDAD 2
SIMULACIÓN Y DIAGNÓSTICO DE TRÁFICO DE RED Y
LATENCIA EN SERVIDORES MEDIANTE DUCKDB Y EXCEL**

**PRESENTADO POR:
KEREN SARAI VILLANUEVA LOPEZ**

**DOCENTE:
ARÍSTIDES CABALLERO ALFARO**

**CUAUTLA, MORELOS, MÉXICO
OCTUBRE, 2026**

Índice

1. Introducción	1
2. Objetivos de la actividad	1
2.1. Objetivo general	1
2.2. Objetivos específicos	1
3. Marco teórico	2
3.1. Medidas de tendencia central y dispersión	2
3.2. Visualización de datos para análisis exploratorio	2
3.3. Identificación de patrones y anomalías: Regla de Tukey	3
3.3.1. Valores esperados del modelo de simulación	3
4. Herramientas utilizadas	3
5. Desarrollo	4
5.1. Fase 1: Generación del conjunto de datos sintético	4
5.2. Fase 2: Caracterización del patrón base	5
5.2.1. Cuestionario reflexivo 1	6
5.3. Fase 3: Detección automatizada de anomalías con la Regla de Tukey	6
5.4. Fase 4: Exportación y validación gráfica en Excel	8
5.5. Registro de comandos (log)	10
6. Conclusiones de ingeniería	11
6.1. ¿Cuántas peticiones fueron clasificadas como anomalías en total?	11
6.2. ¿Qué representa el rango intercuartílico (IQR) en el análisis del rendimiento del servidor?	11
6.3. ¿Qué acciones de infraestructura se recomiendan si este servidor estuviera en producción?	11
6.4. Conclusión general	12

Índice de figuras

1.	Primeros 10 registros de la tabla <code>telemetria_servidor</code>	4
2.	Resultado de las medidas descriptivas calculadas en DuckDB.	5
3.	Clasificación de las peticiones según la Regla de Tukey.	7
4.	Límites de Tukey y conteo total de anomalías.	8
5.	Diagrama de caja y bigotes de la latencia del servidor generado en Excel. . .	9
6.	Fragmento del log de comandos generado por DuckDB.	10

1. Introducción

En la operación de servicios web, la latencia de respuesta es uno de los indicadores más importantes de la calidad del servicio: un servidor puede responder de forma estable durante largos periodos y, de pronto, mostrar valores muy superiores al resto debido a bloqueos de memoria, picos de tráfico o ataques de denegación de servicio. Detectar esos valores atípicos de manera objetiva y automatizada es una tarea central del análisis exploratorio de datos. [1]

El presente informe documenta el desarrollo del Proyecto Integrador de la Unidad 2: *Estadística Descriptiva y Exploratoria*, de la asignatura Análisis y Exploración de Datos (INC-2505). El proyecto abarca las medidas de tendencia central y dispersión, la visualización de datos para análisis exploratorio y la identificación de patrones y anomalías. Como herramientas se utilizaron **DuckDB**, un motor analítico (OLAP) embebido que se ejecuta con SQL [2], para simular la telemetría, calcular las métricas y detectar anomalías, y **Microsoft Excel** para construir el diagrama de caja y bigotes que valida visualmente los resultados.

2. Objetivos de la actividad

2.1. Objetivo general

Caracterizar el comportamiento de la latencia de un servidor web a partir de un conjunto de datos sintético de 100 peticiones, calculando medidas de tendencia central y dispersión, detectando anomalías mediante la Regla de Tukey (IQR) en SQL y validando los resultados con un diagrama de caja y bigotes en Excel.

2.2. Objetivos específicos

- Generar telemetría sintética con funciones aleatorias de DuckDB, con 95 % de peticiones en patrón normal (35 a 65 ms) y 5 % de anomalías de latencia alta (120 a 250 ms).
- Calcular la media, mediana, desviación estándar, mínimo, máximo, cuartiles y rango intercuartílico (IQR) mediante funciones de agregación nativas.
- Implementar un algoritmo SQL con expresiones de tabla comunes (CTE) que clasifique cada petición como patrón normal o anomalía.
- Exportar el conjunto de datos a formato CSV y construir un diagrama de caja y bigotes en Excel para contrastar visualmente la clasificación obtenida en SQL.

3. Marco teórico

3.1. Medidas de tendencia central y dispersión

Las medidas de tendencia central resumen en un solo valor el centro de un conjunto de datos. La **media aritmética** se define como

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad (1)$$

y utiliza todos los valores de la muestra, por lo que es sensible a los valores extremos. La **mediana** es el valor que divide a los datos ordenados en dos mitades iguales; depende de la posición y no de la magnitud de los extremos, por lo que es una medida robusta. [1]

Entre las medidas de dispersión se encuentra la **desviación estándar muestral**,

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}, \quad (2)$$

que cuantifica qué tan alejados están los datos de la media y, al elevar al cuadrado las diferencias, también es sensible a valores atípicos. Los **cuartiles** Q_1 , Q_2 (mediana) y Q_3 dividen la distribución en cuatro partes con igual número de observaciones, y el **rango intercuartílico** (IQR) es

$$\text{IQR} = Q_3 - Q_1, \quad (3)$$

que describe la amplitud del 50 % central de los datos y es robusto ante valores extremos. En DuckDB, la función `quantile_cont` calcula cuantiles con interpolación lineal. [3]

3.2. Visualización de datos para análisis exploratorio

El diagrama de caja y bigotes (*boxplot*), propuesto por Tukey, resume la distribución de una variable con cinco elementos: la caja, delimitada por Q_1 y Q_3 ; una línea interna en la mediana; los bigotes, que se extienden hasta el dato más lejano dentro de los límites de Tukey; y los puntos aislados, que representan los valores atípicos. [1] Es una herramienta apropiada para comparar de forma rápida el centro, la dispersión, la simetría y las anomalías de un conjunto de datos. Excel incorpora este tipo de gráfico entre sus gráficos estadísticos. [4]

3.3. Identificación de patrones y anomalías: Regla de Tukey

La Regla de Tukey considera atípico a todo valor que queda fuera del intervalo

$$[Q_1 - 1,5 \cdot \text{IQR}, Q_3 + 1,5 \cdot \text{IQR}]. \quad (4)$$

Al basarse en cuartiles y no en la media y la desviación estándar, los límites no se distorsionan por los propios valores anómalos, lo que la hace adecuada para detectar picos de latencia. [1]

3.3.1. Valores esperados del modelo de simulación

Dado que la simulación mezcla 95 % de datos uniformes en $[35, 65]$ con 5 % de datos uniformes en $[120, 250]$, es posible anticipar valores teóricos de referencia para validar la ejecución:

- El número de anomalías generadas sigue una distribución binomial $B(100, 0,05)$, con valor esperado $np = 5$ y desviación estándar $\sqrt{np(1-p)} \approx 2,18$; por tanto, en distintas corridas es normal obtener valores cercanos a 5 (por ejemplo, de 2 a 9).
- La media teórica de la mezcla es $0,95(50) + 0,05(185) = 56,75$ ms, mientras que la mediana teórica es aproximadamente 50,79 ms.
- Los cuartiles teóricos son $Q_1 \approx 42,89$ ms y $Q_3 \approx 58,68$ ms, con $\text{IQR} \approx 15,79$ ms, lo que produce límites de Tukey de aproximadamente 19,21 ms (inferior) y 82,37 ms (superior).

Como todas las anomalías simuladas (≥ 120 ms) superan el límite superior y todos los datos normales (≤ 65 ms) quedan por debajo de él, se espera que la regla clasifique exactamente como anomalía a las peticiones generadas por la rama de alta latencia.

4. Herramientas utilizadas

- DuckDB CLI para la generación de datos, el cálculo de métricas y la detección de anomalías. [3]
- Microsoft Excel para la construcción del diagrama de caja y bigotes.
- Archivo de apoyo `proyecto_u2.sql` con las consultas de todas las fases.


5. Desarrollo

5.1. Fase 1: Generación del conjunto de datos sintético

Se creó una tabla temporal con 100 peticiones consecutivas. Cada petición tiene una probabilidad de 5 % de ser una anomalía (latencia entre 120 y 250 ms) y 95 % de seguir el patrón normal del servidor (entre 35 y 65 ms). Para que los resultados sean reproducibles, se fijó una semilla con `setseed`. La función `random()` genera un valor uniforme en $[0, 1)$, que se utiliza para decidir si la petición es normal o anómala y para calcular la latencia correspondiente.

Listing 1: Generación de la telemetría sintética

```
1 CREATE TEMP TABLE telemetria_servidor AS
2 SELECT
3     peticion_id,
4     CASE
5         WHEN random() < 0.05 THEN ROUND(120 + (random() * 130), 2)
6         ELSE ROUND(35 + (random() * 30), 2)
7     END AS latencia_ms
8 FROM generate_series(1, 100) AS t(peticion_id);
9
10 SELECT * FROM telemetria_servidor LIMIT 10;
```



peticion_id int64	latencia_ms double
1	40.48
2	44.6
3	49.66
4	50.96
5	38.16
6	36.75
7	49.7
8	42.42
9	43.11
10	60.34

10 rows 2 columns

Figura 1: Primeros 10 registros de la tabla `telemetria_servidor`.

5.2. Fase 2: Caracterización del patrón base

Se calcularon las medidas de tendencia central y dispersión con las funciones AVG, MEDIAN, STDDEV y quantile_cont.

Listing 2: Cálculo de medidas descriptivas

```
1 SELECT
2     ROUND(AVG(latencia_ms), 2)           AS Media ,
3     ROUND(MEDIAN(latencia_ms), 2)        AS Mediana ,
4     ROUND(STDDEV(latencia_ms), 2)        AS
5         Desviacion_Estandar ,
6     ROUND(MIN(latencia_ms), 2)           AS Minimo ,
7     ROUND(MAX(latencia_ms), 2)           AS Maximo ,
8     ROUND(quantile_cont(latencia_ms, 0.25), 2) AS Q1_Cuartil1 ,
9     ROUND(quantile_cont(latencia_ms, 0.75), 2) AS Q3_Cuartil3 ,
10    ROUND(quantile_cont(latencia_ms, 0.75)
11    - quantile_cont(latencia_ms, 0.25), 2) AS IQR
FROM telemetria_servidor;
```

Media double	Mediana double	Desviacion_Estandar double	Minimo double	Maximo double	Q1_Cuartil1 double	Q3_Cuartil3 double	IQR double
55.44	49.95	29.8	35.02	242.39	42.46	57.65	15.2

Figura 2: Resultado de las medidas descriptivas calculadas en DuckDB.

Tabla 1: Medidas descriptivas de la latencia (ms) obtenidas en la ejecución.

Medida	Valor (ms)
Media	55.44
Mediana	49.95
Desviación estándar	29.80
Mínimo	35.02
Máximo	242.39
Q_1	42.46
Q_3	57.65
IQR	15.20

5.2.1. Cuestionario reflexivo 1

Pregunta: Compara el valor de la media respecto a la mediana. Explica por qué la presencia de picos de latencia desvía la media hacia un valor más alto, mientras la mediana se mantiene estable.

Respuesta: En la ejecución se obtuvo una media de 55.44 ms y una mediana de 49.95 ms, es decir, la media resultó 5.49 ms mayor. La media se calcula sumando todos los valores, de modo que una petición de, por ejemplo, 200 ms contribuye con su magnitud completa y arrastra el promedio hacia arriba, aun cuando la gran mayoría de las peticiones esté cerca de 50 ms. La mediana, en cambio, solo depende de cuál es el valor que ocupa la posición central al ordenar los datos: que un extremo valga 130 o 250 ms no cambia su posición, por lo que la mediana permanece dentro del rango normal (35 a 65 ms) y refleja el verdadero patrón central del servidor. La desviación estándar de 29.80 ms, mucho mayor que la que tendría el tráfico normal por sí solo (alrededor de 8.7 ms para una distribución uniforme entre 35 y 65), también se infla por la presencia de los picos.

5.3. Fase 3: Detección automatizada de anomalías con la Regla de Tukey

Se implementó la Regla de Tukey mediante dos CTE: `metricas`, que obtiene Q_1 , Q_3 e IQR, y `limites`, que calcula los límites inferior y superior. Posteriormente, cada petición se compara contra dichos límites para asignarle un diagnóstico.

Listing 3: Clasificación de peticiones con la Regla de Tukey

```
1 WITH metricas AS (  
2     SELECT  
3         quantile_cont(latencia_ms, 0.25) AS Q1,  
4         quantile_cont(latencia_ms, 0.75) AS Q3,  
5         (quantile_cont(latencia_ms, 0.75)  
6         - quantile_cont(latencia_ms, 0.25)) AS IQR  
7     FROM telemetria_servidor  
8 ),  
9 limites AS (  
10    SELECT  
11        Q1, Q3, IQR,  
12        (Q1 - 1.5 * IQR) AS limite_inferior,  
13        (Q3 + 1.5 * IQR) AS limite_superior  
14    FROM metricas
```

```

15 )
16 SELECT
17     t.peticion_id,
18     t.latencia_ms,
19     CASE
20         WHEN t.latencia_ms > l.limite_superior THEN 'ANOMALÍA (
                Spike Alto)'
21         WHEN t.latencia_ms < l.limite_inferior THEN 'ANOMALÍA (Bajo
                Rango)'
22         ELSE 'Patrón Normal'
23     END AS diagnostico_sistema
24 FROM telemetria_servidor t, limites l
25 ORDER BY t.peticion_id;

```

peticion_id	latencia_ms	diagnostico_sistema
int64	double	varchar
1	40.48	Patrón Normal
2	44.6	Patrón Normal
3	49.66	Patrón Normal
4	50.96	Patrón Normal
5	38.16	Patrón Normal
6	36.75	Patrón Normal
7	49.7	Patrón Normal
8	42.42	Patrón Normal
9	43.11	Patrón Normal
10	60.34	Patrón Normal

Figura 3: Clasificación de las peticiones según la Regla de Tukey.

Cabe señalar que en la guía original la cláusula `FROM` de la CTE `limites` aparece vacía; se corrigió a `FROM metricas`. Para responder cuántas peticiones fueron anómalas y qué umbrales se aplicaron, se agregó una consulta de conteo.

Listing 4: Conteo de anomalías y límites de Tukey

```

1 WITH m AS (
2     SELECT quantile_cont(latencia_ms, 0.25) AS Q1,
3            quantile_cont(latencia_ms, 0.75) AS Q3
4     FROM telemetria_servidor
5 ),

```

```

6 1 AS (
7     SELECT Q1, Q3, Q1 - 1.5*(Q3-Q1) AS lim_inf,
8           Q3 + 1.5*(Q3-Q1) AS lim_sup
9     FROM m
10 )
11 SELECT
12     ROUND(l.lim_inf, 2) AS limite_inferior,
13     ROUND(l.lim_sup, 2) AS limite_superior,
14     COUNT(*) FILTER (WHERE t.latencia_ms > l.lim_sup) AS
15         anomalias_spike_alto,
16     COUNT(*) FILTER (WHERE t.latencia_ms < l.lim_inf) AS
17         anomalias_bajo_rango,
18     COUNT(*) FILTER (WHERE t.latencia_ms > l.lim_sup
19                       OR t.latencia_ms < l.lim_inf) AS
20         total_anomalias
21 FROM telemetria_servidor t, l
22 GROUP BY l.lim_inf, l.lim_sup;

```

limite_inferior double	limite_superior double	anomalias_spike_alto int64	anomalias_bajo_rango int64	total_anomalias int64
19.66	80.45	4	0	4

Figura 4: Límites de Tukey y conteo total de anomalías.

Los límites obtenidos fueron $[19,66, 80,45]$ ms, y se identificaron 4 peticiones anómalas, todas ellas de tipo *Spike Alto*. La Tabla 2 lista las peticiones detectadas.

Tabla 2: Peticiones clasificadas como anomalía (Spike Alto).

peticion_id	latencia_ms
83	242.39
66	183.33
33	177.43
61	162.86

5.4. Fase 4: Exportación y validación gráfica en Excel

Los datos se exportaron a un archivo CSV con el siguiente comando:

Listing 5: Exportación de la tabla a CSV

```
1 COPY telemetria_servidor TO 'telemetria_servidor.csv' (HEADER,
    DELIMITER ',');
```

El archivo resultante contiene dos columnas: `peticion_id` (columna A) y `latencia_ms` (columna B). Por ello, para el diagrama se seleccionó el rango **B1:B101**, que corresponde a la latencia, y no A1:A101 como indicaba la guía. Posteriormente se utilizó *Insertar* → *Gráficos estadísticos* → *Caja y bigotes*, se activó la opción de mostrar puntos atípicos y el cálculo de cuartiles con mediana inclusiva (equivalente a la interpolación de `quantile_cont`), y se configuraron el título del gráfico y los títulos y escala del eje vertical.




Figura 5: Diagrama de caja y bigotes de la latencia del servidor generado en Excel.

Validación: en la Figura 5 se observa que las 4 peticiones clasificadas en SQL como *ANOMALÍA (Spike Alto)* aparecen como puntos aislados por encima del bigote superior, mientras que el resto de las peticiones queda contenido dentro de la caja y los bigotes. El bigote superior termina en aproximadamente 64.99 ms, valor coherente con el dato normal más alto y con el límite superior de 80.45 ms calculado en SQL. Esto confirma que el algoritmo SQL y la herramienta gráfica aplican el mismo criterio.


5.5. Registro de comandos (log)

Para cumplir con el entregable, la salida del CLI de DuckDB se redirigió a un archivo de texto al ejecutar el script del proyecto.

Listing 6: Generación del log de comandos

```
1  -- Opcion 1: ejecutar todo el script y guardar la salida
2  --    duckdb < proyecto_u2.sql > log_comandos_23680116_U2.txt
3
4  -- Opcion 2: dentro del CLI
5  .output log_comandos_23680116_U2.txt
6  .echo on
7  -- ... ejecutar las fases 1 a 4 ...
8  .output stdout
```

El archivo generado, `log_comandos_23680116_U2.txt`, se adjunta como entregable independiente, junto con el PDF del diagrama de caja y bigotes.



```
Unidad2 > pi2 >  log_comandos_23680116_U2.txt
8
9  CREATE TEMP TABLE telemetria_servidor AS
10 SELECT
11     petition_id,
12     CASE
13         WHEN random() < 0.05 THEN ROUND(120 + (random() * 130), 2)
14         ELSE ROUND(35 + (random() * 30), 2)
15     END AS latencia_ms
16 FROM generate_series(1, 100) AS t(petition_id);
17
18 SELECT * FROM telemetria_servidor LIMIT 10;
19
20  petition_id  latencia_ms
21  int64        double
22
23  1            40.48
24  2            44.6
25  3            49.66
26  4            50.96
27  5            38.16
28  6            36.75
29  7            49.7
30  8            42.42
31  9            43.11
32  10           60.34
33
34  10 rows      2 columns
```

Figura 6: Fragmento del log de comandos generado por DuckDB.

6. Conclusiones de ingeniería

6.1. ¿Cuántas peticiones fueron clasificadas como anomalías en total?

Se clasificaron 4 de las 100 peticiones como anomalías, es decir, el 4 % de la muestra, todas de tipo *Spike Alto*. Este resultado es consistente con el modelo de simulación: como cada petición tiene 5 % de probabilidad de ser anómala, el número esperado es de 5 con una desviación estándar de aproximadamente 2.2, por lo que variaciones entre corridas son normales.

6.2. ¿Qué representa el rango intercuartílico (IQR) en el análisis del rendimiento del servidor?

El IQR, que en esta ejecución fue de 15.20 ms, representa la amplitud del 50 % central de las latencias; es decir, qué tanto varía el tiempo de respuesta durante la operación típica del servidor, sin influencia de los picos. Un IQR pequeño indica un servicio estable y predecible; un IQR grande, un servicio irregular. Además, el IQR define los umbrales de la Regla de Tukey, de modo que el criterio de anomalía se adapta al comportamiento real del servidor en lugar de depender de un valor fijo arbitrario, y no se contamina con los propios picos que busca detectar, a diferencia de un criterio basado en la media y la desviación estándar.

6.3. ¿Qué acciones de infraestructura se recomiendan si este servidor estuviera en producción?

- **Monitoreo y alertas:** vigilar percentiles altos (p95 y p99) y configurar alertas automáticas cuando la latencia supere el límite de Tukey calculado sobre una ventana móvil, en lugar de basarse solo en el promedio.
- **Escalamiento y balanceo de carga:** implementar autoescalado horizontal y balanceadores de carga para absorber picos legítimos de tráfico.
- **Protección contra ataques:** aplicar limitación de tasa (*rate limiting*), un firewall de aplicaciones web y servicios de mitigación de denegación de servicio.
- **Diagnóstico de memoria:** revisar el uso de memoria y el recolector de basura para identificar fugas o bloqueos que expliquen picos aislados.

- **Tolerancia a fallos:** usar caché, *timeouts* y *circuit breakers* para evitar que una petición lenta se propague a otros servicios.
- **Mejora continua:** realizar pruebas de carga periódicas y mantener un procedimiento documentado de respuesta a incidentes, registrando la causa de cada anomalía detectada.

6.4. Conclusión general

Este proyecto permitió integrar los tres temas de la unidad: las medidas descriptivas dieron el patrón base del servidor, la visualización con el diagrama de caja y bigotes permitió ver de un vistazo la dispersión y los valores extremos, y la Regla de Tukey convirtió esa intuición visual en un criterio automatizable en SQL. Una enseñanza central fue la diferencia entre medidas sensibles (media y desviación estándar) y medidas robustas (mediana e IQR) ante valores atípicos: las segundas describen mejor el comportamiento normal, y las primeras sirven, precisamente, para evidenciar que algo anómalo ocurrió. También quedó clara la utilidad de contrastar un resultado obtenido por cálculo con una representación gráfica independiente, ya que ambas coinciden en confirmar el diagnóstico y ayudan a detectar errores, como los dos que se corrigieron en la guía original (la cláusula `FROM` vacía y el rango de columna).

Referencias

- [1] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA, USA: Addison-Wesley, 1977.
- [2] M. Raasveldt and H. Mühleisen, “DuckDB: an embeddable analytical database,” in *Proceedings of the 2019 International Conference on Management of Data (SIGMOD '19)*, pp. 1981–1984, ACM, 2019.
- [3] DuckDB Foundation, “DuckDB documentation: Aggregate functions.” <https://duckdb.org/docs/>. Consultado en 2026.
- [4] Microsoft, “Create a box and whisker chart.” <https://support.microsoft.com/>. Soporte de Microsoft Office. Consultado en 2026.